

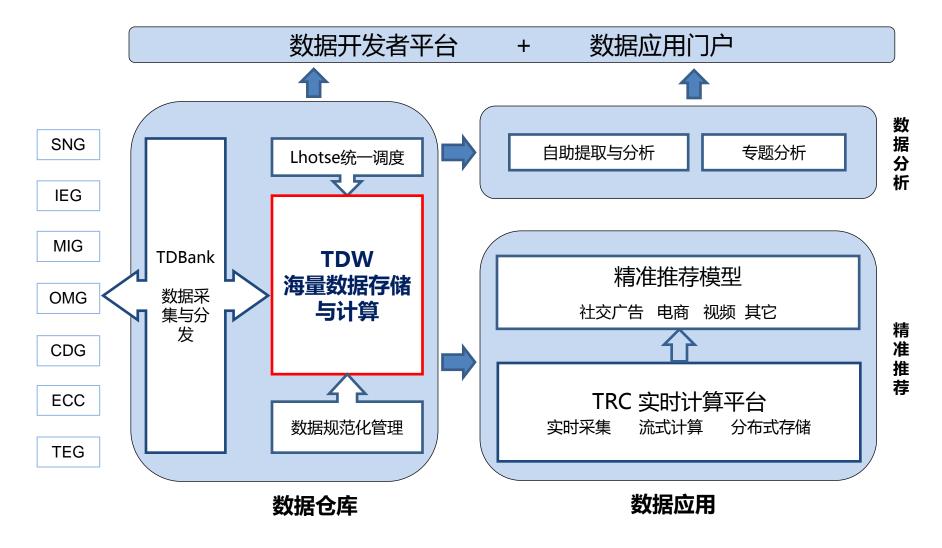
# 腾讯大规模 Hadoop集群实践

腾讯数据平台部

翟艳堂



### 数据服务总体框架





#### 为什么要做大集群

- 数据共享
- 计算资源共享
- 减轻运营负担





### 面临的挑战

400台 4000台

- ▶计算层
  - JobTracker调度效率低 集群扩展性不好

#### ▶存储层

● NameNode没有容灾

丢失1个小时数据的风险

重启耗时长

不支持灰度变更



JobTracker分散化 NameNode高可用 高可用

高效

高扩展性



# JobTracker分散化



## 方案选择

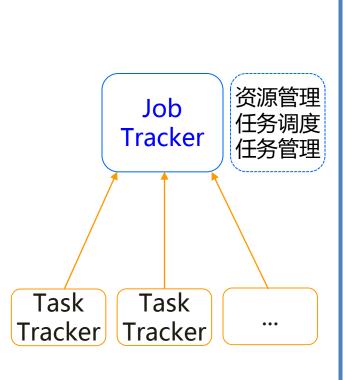
TDW基线版本: CDH3u3

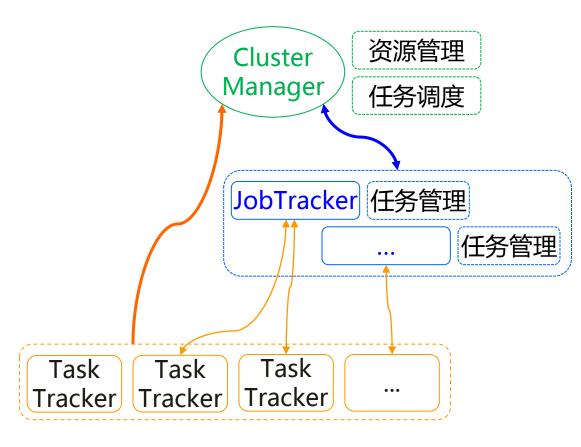
	Yarn	Corona
版本稳定性	社区开发中,稳定版发布时间未知	facebook发布的版本
代码复杂度	2.X系列代码,完全重构	基于0.20系列代码
HDFS的要求	2.X HDFS	0.20系统HDFS

时间:2012年12月



#### JobTracker分散化

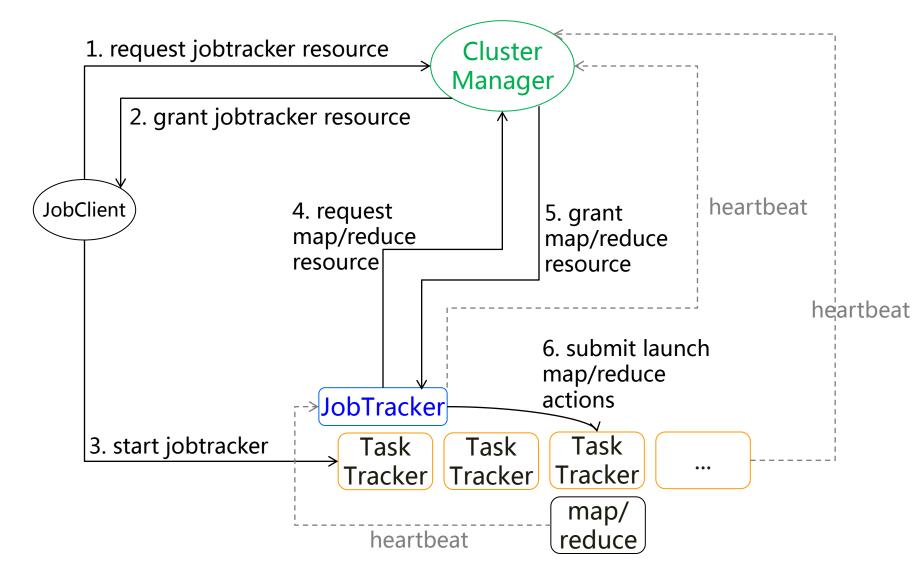




- ➤ JobTracker分散化平行扩展
- > 资源管理和任务调度解耦
- > 更精细地调度



### JobTracker分散化

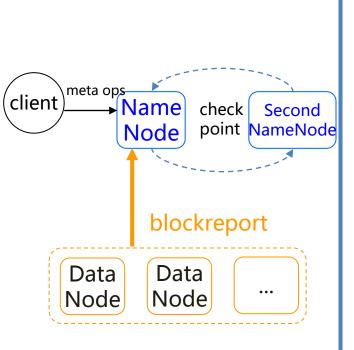


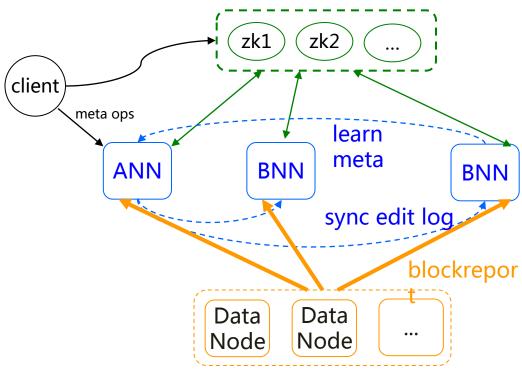


# NameNode高可用



### NameNode高可用

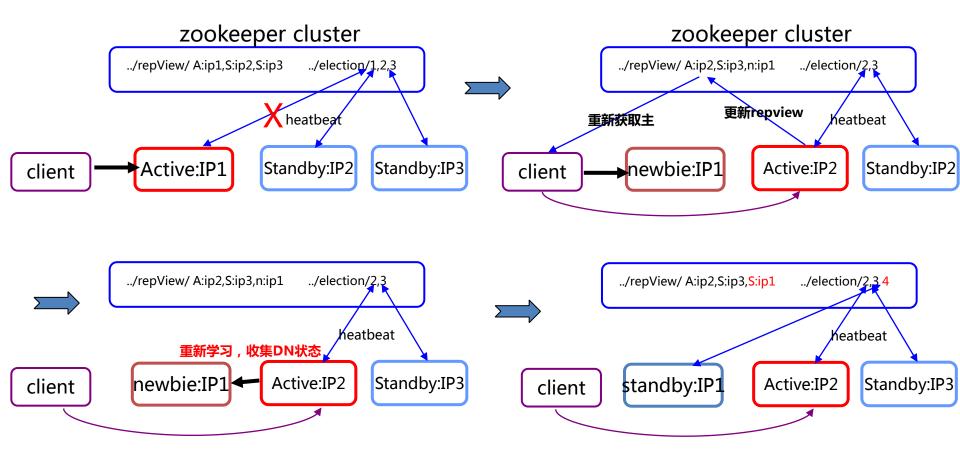




- > 一主两热备
- 元数据在主备间实时同步
- ➤ DataNode同时向3个Master汇报Block



#### Namenode主备仲裁以及状态转换

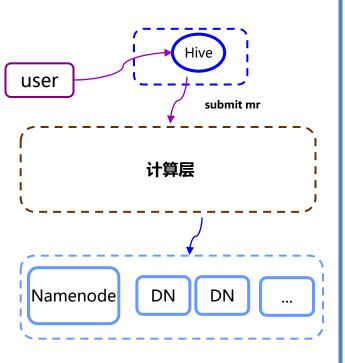


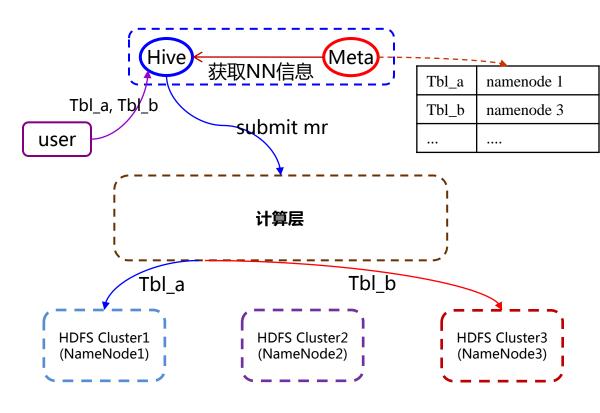


# NameNode分散化



#### NameNode分散化





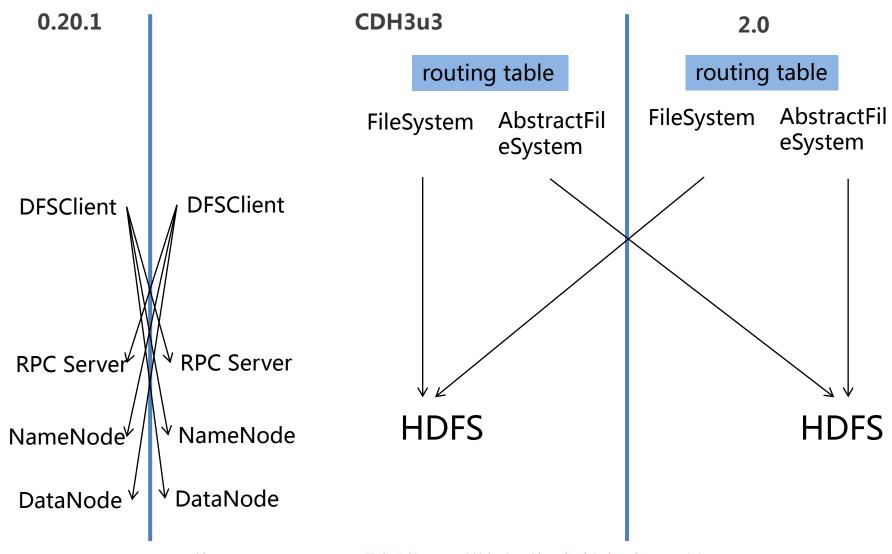
- > 按业务分布
- > 按负载分布资源



# 优化运营



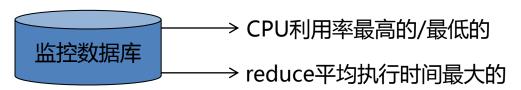
#### HDFS兼容





### 检测节点短板

• 1个节点慢,整个job慢



#### 推测执行差异化服务

- 一视同仁
  - 资源浪费
- 关键任务不能执行慢,非关键任务不能卡死

	关键任务	非关键任务
推测比例	90%	1%
推测间隔	5s	30m



### 防止数据误删除

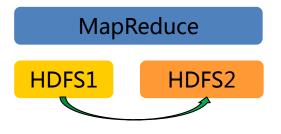
- 误删除数据将会造成灾难
  - NameNode回收站
  - 删除黑白名单
  - DataNode回收站

### 大Job的困扰

- 资源池限制
- 生产时段和非生产时段动态调整
- 下手狠一点



#### 业务迁移



soso\_wap库表活跃分析 时间 ◆表更新时间 24 22 20 18 16 智能计算可实施 切换时间 14 12 10 2 表的数字标记 20 40 100 120 60 80

- · DB为迁移切换单位
- 计算出空窗期
- 全量迁移DB
- 循环补充迁移更新的表
  - 实施切换

Linux公社(www.LinuxIDC.com)是专业的Linux系统门户网站,实时发布最新Linux资讯。



## 集群发展现状

单集群支撑规模	400	4400
每日作业数	4万	100万+
每日计算量	0.26PB	4PB
存储利用率	85%+	83%+
CPU利用率	30%	85%+
数据安全性	可能会丢失1个小时 数据	丟数据风险很低
重启暂停线上服 务时间	1小时	秒级自动无缝切换
总存储量	4PB	80PB
文件数+块数	5千万	6亿

#### 集群容量

- -服务器 4400台
- -CPU~10w+核
- -内存~275TB
- -磁盘~52800块
- -存储容量~100PB



### 未来计划

- · 引入Yarn作为统一的资源管理平台
  - 支持MapReduce、Storm、Spark、Tez等计算模型
- 实时计算平台
- 类Dremel系统
- 开源计划



# 谢谢